Բովանդակություն

Ներածություն.....2

ԳԼՈՒԽ 1. ԳՐԱՖՆԵՐԻ ՏԵՍՈՒԹՅԱՆ ՀԻՄՆԱԿԱՆ ՀԱՍԿԱՑՈՒԹՅՈՒՆՆԵՐԸ ԵՎ ՕԳՏԱԳՈՐԾՎՈՂ ԱԼԳՈՐԻԹՄՆԵՐԻ ՍԱՀՄԱՆՈՒՄՆԵՐԸ.....5

1.1. Գրաֆներ, գագաթներ, կողեր և նրանց հիմնական հատկությունները.....5

1.2. Օգտագործվող ալգորիթմների սահմանումներ, բանաձևեր և բացատրություններ.....13

Ներածություն

Վերջին տասնամյակներում սոցիալական ցանցերը դարձել են տեղեկատվական հասարակության ամենաազդեցիկ երևույթներից մեկը: Օգտատերերը ոչ միայն փոխանակում են անձնական հաղորդագրություններ և լուսանկարներ, այլև մասնակցում են հանրային քննարկումների, ձևավորում կարծիքներ, մասնակցում քաղաքական, տնտեսական և մշակութային գործընթացներին: Սոցիալական հարթակները դարձել են կարևոր գործիք բիզնեսի, կրթության, քաղաքացիական նախաձեռնությունների և նույնիսկ ճգնաժամերի կառավարման համար: Այս համատեքստում դրանց կառուցվածքի և դինամիկայի խորքային վերլուծությունը ստանում է թե՛ տեսական, թե՛ կիրառական մեծ նշանակություն:

Սոցիալական ցանցերի կառուցվածքն ու դրանցում տեղի ունեցող գործընթացները բնութագրվում են բազում ոչ ուղիղ, ոչ գծային փոխազդեցություններով: Օգտատերերի միջև կապերը միմյանցից անկախ չեն, իսկ տեղեկատվության տարածումը հաճախ ունի կասկադային բնույթ: Տեղեկատվական «վիրուսները», մարքեթինգային արշավները, քարոզչական հաղորդագրությունները կամ հասարակական շարժումները կարող են կարճ ժամանակում հասնել միլիոնավոր օգտատերերի: Այս երևույթները հասկանալու համար անհրաժեշտ է կիրառել մաթեմատիկական խիստ գործիքակազմ, որը թույլ է տալիս մոդելավորել և վերլուծել մեծածավալ ցանցեր:

Գրաֆների տեսությունը հանդիսանում է այդպիսի գործիքակազմի հիմնասյուներից մեկը: Սոցիալական ցանցը ներկայացնելով որպես գրաֆ $G = (V, E)$, որտեղ V բազմության տարրերը օգտատերերն են, իսկ E բազմության տարրերը՝ նրանց միջև կապերը, դառնում է հնարավոր կիրառել կառուցվածքային և սպեկտրալ անալիզի մեթոդներ, գնահատել կենտրոնականությունը, բացահայտել համայնքները, մոդելավորել տեղեկատվության հոսքերը և կանխատեսել ապագա կապերի առաջացումը: Այս մոտեցումը թույլ է տալիս անցնել ինտուիտիվ մտածողությունից դեպի քանակական վերլուծություն:

Սույն դիպլոմային աշխատանքի շրջանակում սոցիալական ցանցի մոդելավորման և վերլուծության հիմքում դրված է գրաֆների տեսության չորս հիմնական մեթոդի կիրառումը. համայնքների հայտնաբերման համար օգտագործվում է Louvain ալգորիթմը, ազդեցիկ օգտատերերի գնահատման համար՝ PageRank ցուցիչը, տեղեկատվության տարածման դինամիկան մոդելավորվում է Linear Threshold մոդելով, իսկ ապագա կապերի (friend recommendation) հավանականությունը գնահատվում է Adamic–Adar ցուցիչի օգնությամբ: Այս ընտրությունը թույլ է տալիս դիտարկել սոցիալական ցանցը միաժամանակ կառուցվածքային, դինամիկ և կանխատեսական տեսանկյուններից:

Աշխատանքի արդիականությունը պայմանավորված է մի քանի գործոններով: Նախ, սոցիալական ցանցերը շարունակում են արագ աճել թե՛ չափերով, թե՛ ազդեցությամբ, և դրանցում տեղի ունեցող գործընթացների մոդելավորումը կարևոր է մարքեթինգի, բիզնես անալիտիկայի, տեղեկատվության անվտանգության, ինչպես նաև հանրային քաղաքականության մշակման համար: Երկրորդ, գրաֆների տեսության մեթոդների կիրառումը թույլ է տալիս ստեղծել ընդհանուր մոտեցումներ, որոնք անկախ են կոնկրետ հարթակից (Facebook, Instagram, Twitter և այլն) և կարող են վերաօգտագործվել տարբեր տեսակի ցանցերի համար: Երրորդ, Louvain, PageRank, Linear Threshold և Adamic–Adar մեթոդների համակցված կիրառումը հնարավորություն է տալիս ստանալ բազմաչափ պատկեր ցանցի կառուցվածքի և զարգացման հնարավոր սցենարների մասին:

Հետազոտության օբյեկտն է սոցիալական ցանցի գրաֆային մոդելը՝ օգտատերերի և նրանց միջև կապերի ամբողջության տեսքով:

Հետազոտության առարկան են ցանցի կառուցվածքային հատկությունները, տեղեկատվության տարածման գործընթացները և ապագա կապերի ձևավորման օրինաչափությունները, որոնք ուսումնասիրվում են գրաֆների տեսության գրեթե մեթոդների կիրառման միջոցով:

Աշխատանքի նպատակը սոցիալական ցանցի կառուցվածքի վերլուծությունն ու դրա դինամիկայի մոդելավորումն է՝ Louvain, PageRank, Linear Threshold և Adamic–Adar

մեթոդների համատեղ կիրառման միջոցով: Նպատակին հասնելու համար ձևակերպվում են հետևյալ հիմնական ենթախնդիրները.

- հայտնաբերել ցանցի համայնքային կառուցվածքը և գնահատել մոդուլայնությունը,
- որոշել առավել ազդեցիկ օգտատերերին կենտրոնականության չափիչների հիման վրա,
- մոդելավորել տեղեկատվության տարածման կասկադային գործընթացը տարբեր seed-ստրատեգիաների դեպքում,
- գնահատել ապագա կապերի առաջացման հավանականությունը Adamic–Adar և կապված ցուցիչների միջոցով:

Հետազոտության մեթոդաբանական հիմքը կազմում են գրաֆների տեսության դասական սահմանումներն ու դրույթները, Louvain և PageRank ալգորիթմների վրա հիմնված կառուցվածքային վերլուծությունը, Linear Threshold մոդելի միջոցով դինամիկ գործընթացների մոդելավորումը և Adamic–Adar ցուցիչի վրա հիմնված link prediction տեխնիկան: Աշխատանքի տեսական մասը մանրամասն ներկայացնում է օգտագործվող հասկացությունները, նշումները և բանաձևերը, ինչից հետո դրանք կիրառվում են կոնկրետ սոցիալական ցանցի մոդելի վրա:

Աշխատանքի գիտական նորույթը կապված է այն հանգամանքի հետ, որ սոցիալական ցանցի վերլուծությունն իրականացվում է ոչ թե մեկ առանձին մեթոդի, այլ չորս փոխլրացնող մեթոդների համակցման միջոցով, որն ապահովում է ցանցի կառուցվածքի և դինամիկայի համակողմանի գնահատում: Ավելին, առաջարկվում է միասնական մոտեցում, որը միավորում է համայնքային կառուցվածքի, կենտրոնականության, տեղեկատվության տարածման և ապագա կապերի կանխատեսման խնդիրները միևնույն մաթեմատիկական շրջանակում:

Աշխատանքի կիրառական նշանակությունը դրսևորվում է այն հնարավորության մեջ, որ ստացված մոդելներն ու ալգորիթմական մոտեցումները կարող են օգտագործվել սոցիալական հարթակների անալիտիկայի, recommender համակարգերի նախագծման,

թիրախավորված մարքեթինգի, ինչպես նաև տեղեկատվական հոսքերի վերահսկման և անվտանգության ապահովման խնդիրներում:

Դիպլոմային աշխատանքի կառուցվածքը հետևյալն է. ներմուծությունից հետո Գլուխ 1-ում ներկայացվում են գրաֆների տեսության հիմնական սահմանումները, օգտագործվող ալգորիթմների մաթեմատիկական ձեւակերպումները և նրանց վերաբերյալ անհրաժեշտ դրույթներն ու ապացույցները, ինչպես նաև մեկնաբանությունները տրված նախագծի կոնտեքստում: Գլուխ 2-ում ձևակերպվում է հիմնական խնդիրը, բացատրվում է տվյալների նախնական մշակումն ու գրաֆի կառուցման գործընթացը, ներկայացվում են ընտրված մեթոդների կիրառության սխեմաները և քննարկվում են կիրառական սցենարները: Հաջորդ գլուխներում (որոնք կավելացվեն հետագայում) պլանավորվում է ներկայացնել կոնկրետ սոցիալական ցանցի տվյալների հիման վրա ստացված փորձարկումները, վերլուծությունները և եզրակացությունները:

ԳԼՈՒԽ 1. ԳՐԱՖՆԵՐԻ ՏԵՍՈՒԹՅԱՆ ՀԻՄՆԱԿԱՆ ՀԱՍԿԱՑՈՒԹՅՈՒՆՆԵՐԸ ԵՎ ՕԳՏԱԳՈՐԾՎՈՂ ԱԼԳՈՐԻԹՄՆԵՐԻ ՍԱՀՄԱՆՈՒՄՆԵՐԸ

1.1. Գրաֆներ, գագաթներ, կողեր և նրանց հիմնական հատկությունները

Սահմանում 1.1.1 (Գրաֆ). Թող $V = \{v_1, v_2, \dots, v_n\}$լինի վերջավոր, ոչ դատարկ բազմություն, իսկ $E \subseteq V \times V$՝ կապերի բազմություն: Կարգավորված զույգը $G = (V, E)$կոչվում է գրաֆ: Եթե $(u, v) \in E$, ապա ասում ենք, որ uև vգագաթները միացված են կողով կամ հարևան են:

Մեկնաբանություն 1.1.1. Սույն նախագծում գրաֆը մոդելավորում է սոցիալական ցանցը. գագաթները ներկայացնում են օգտատերերին, իսկ կողերը՝ նրանց միջև սոցիալական կապերը (ընկերություն, հետևել, հաղորդագրություն և այլն): Ալգորիթմների ամբողջ վերլուծությունը իրականացվում է հենց այս $G = (V, E)$մոդելի վրա:

Սահմանում 1.1.2 (Պարզ գրաֆ). Գրաֆ $G = (V, E)$-ը կոչվում է պարզ, եթե այն չունի բազմակի կողեր (երկու գագաթների միջև ոչ մեկից ավելի կող) և ինքնակողեր (գագաթից ինքն իրեն կող):

Մեկնաբանություն 1.1.2. Սոցիալական ցանցի մեծ մասն իրականացումներում ընկալվում է պարզ գրաֆ՝ երկու օգտատերերի միջև կամ կա ընկերություն, կամ չկա, և օգտատերը չի կարող ինքն իրեն «ընկեր» լինել: Այս պարզեցումը թույլ է տալիս կիրառել դասական գրաֆային ալգորիթմներ առանց լրացուցիչ բարդությունների:

Սահմանում 1.1.3 (Հարևանություն և աստիճան). $G = (V, E)$գրաֆում $u, v \in V$գագաթները կոչվում են հարևան, եթե նրանց միջև կա կող: Տրված $v \in V$գագաթի աստիճանը $d_G(v)$սահմանվում է որպես v-ին կից կողերի քանակը՝

$$d_G(v) = |\{e \in E(G): v \in e\}|$$

Մեկնաբանություն 1.1.3. Աստիճանը նախագծում բնութագրում է օգտատիրոջ անմիջական կապերի քանակը: Բարձր $d_G(v)$ունեցող օգտատերերը ունեն մեծ սոցիալական շրջապատ և կարող են դիտվել որպես ավելի ակտիվ կամ լավ «կապակցված» հանգույցներ, ինչը կարևոր է ինչպես ազդեցիկ օգտատերերի վերլուծության, այնպես էլ համայնքային կառուցվածքի հասկացման համար:

Սահմանում 1.1.4 (Նվազագույն և առավելագույն աստիճան). Գրաֆի նվազագույն և առավելագույն աստիճանները սահմանվում են հետևյալ կերպ՝

$$\delta(G) = \min_{v \in V(G)} d_G(v), \Delta(G) = \max_{v \in V(G)} d_G(v)$$

Մեկնաբանություն 1.1.4. Այս երկու մեծությունները նախագծում կիրառվում են որպես նախնական վիճակագրական ցուցիչներ՝ գնահատելու ցանցի հոմոգենությունը: Եթե $\Delta(G)$շատ մեծ է $\delta(G)$-ի համեմատ, ապա ցանցում կան «գերտարածված» օգտատերեր (հուբեր), որոնց շուրջ է կենտրոնացած մեծ քանակի կապեր:

Թեորեմ 1.1.5 (Աստիճանների գումարի բանաձև). Թող $G = (V, E)$լինի վերջավոր, պարզ, անկողմնորոշ գրաֆ: Այդ դեպքում գագաթների աստիճանների գումարը հավասար է կողերի թվի կրկնապատիկին՝

$$\sum_{v \in V(G)} d_G\,(v) = 2 \mid E(G) \mid$$

Ապացույց. Յուրաքանչյուր $e = \{u, v\} \in E(G)$կողը կպչում է ճիշտ երկու գագաթների՝ u և v: Աստիճանների գումարի մեջ յուրաքանչյուր կող հաշվի է առնվում երկու անգամ՝ իր յուրաքանչյուր վերջնակետի աստիճանում մեկ անգամ:

Մեկնաբանություն 1.1.5. Այս բանաձևը նախագծում օգտագործվում է հիմնականում որպես consistency check՝ ստուգելու, թե արդյոք սոցիալական ցանցի տվյալներից կառուցված գրաֆը ճիշտ է ներկայացվել (կողերի թվի և աստիճանների գումարի համապատասխանություն):

Հետևանք 1.1.6. Ցանկացած գրաֆում կենտ աստիճան ունեցող գագաթների քանակը զույգ է:

Ապացույց. Թող V_{odd}և V_{even}բազմությունները համապատասխանաբար կենտ և զույգ աստիճան ունեցող գագաթներն են: Թեորեմ 1.1.5-ից՝

$$\sum_{v \in V_{\text{odd}}} d_G\,(v) + \sum_{v \in V_{\text{even}}} d_G\,(v) = 2 \mid E(G) \mid.$$

Աջ կողմը զույգ է, երկրորդ գումարը նույնպես զույգ է (զույգ թվերի գումար), հետևաբար առաջին գումարը պետք է զույգ լինի: Քանի որ յուրաքանչյուր անդամ կենտ է, դրանց քանակը պետք է զույգ լինի:

Մեկնաբանություն 1.1.6. Սա ապացուցում է ավելի խորը կառուցվածքային հատկություն, որը կիրառվում է գրաֆների ճիշտ կառուցման և տվյալների վավերականության ստուգման համար:

Սահմանում 1.1.7 (Ճանապարհ և երկարություն). Գագաթների հաջորդականությունը $P = (v_0, v_1, \dots, v_k)$կոչվում է ճանապարհ երկարությամբ k, եթե յուրաքանչյուր $i \in \{1,2, \dots, k\}$-ի համար գագաթները v_{i-1}և v_iհարևան են:

Մեկնաբանություն 1.1.7. Ճանապարհի երկարությունը չափում է, թե քանի «քայլ» է հարկավոր անցնել մեկ օգտատիրոջից մյուսին հասնելու համար: Սա հիմք է կազմում տեղեկատվության տարածման դինամիկայի վերլուծության համար:

Սահմանում 1.1.8 (Պարզ ճանապարհ և ցիկլ). Ճանապարհը կոչվում է պարզ, եթե նրա բոլոր գագաթները տարբեր են (բացառությամբ, հնարավոր է, սկզբնականի և վերջնականի): Եթե $v_0 = v_k$և $k \geq 3$, ճանապարհը կոչվում է ցիկլ:

Մեկնաբանություն 1.1.8. Ցիկլերի առկայությունը սոցիալական ցանցում ցույց է տալիս փակ «շրջանակներ» կամ փոխադարձ կապակցված խմբեր, որոնք կարևոր են համայնքների ձևավորման համար:

Սահմանում 1.1.9 (Հեռավորություն). Երկու $u, v \in V$գագաթների միջև հեռավորությունը $d_G(u, v)$սահմանվում է որպես u-ից vամենակարճ ճանապարհի երկարությունը: Եթե ճանապարհ չկա, $d_G(u, v) = +\infty$:

Մեկնաբանություն 1.1.9. Հեռավորության հասկացությունը նախագծում կիրառվում է «small-world» հատկության վերլուծության համար և գնահատելու, թե որքան արագ կարող է տեղեկատվությունը հասնել մեկ օգտատիրոջից մյուսին: Սա անմիջականորեն կապ ունի Linear Threshold մոդելի սիմուլյացիաների արդյունքների հետ:

Սահմանում 1.1.10 (Կապակցված գրաֆ և բաղադրիչ). Գրաֆը կոչվում է կապակցված, եթե ցանկացած երկու $u, v \in V$գագաթների միջև գոյություն ունի ճանապարհ: Կապակցված բաղադրիչը գրաֆի մաքսիմալ կապակցված ենթագրաֆն է:

Մեկնաբանություն 1.1.10. Նախագծում հիմնական վերլուծությունները կատարվում են ցանցի գլխավոր կապակցված բաղադրիչի վրա, քանի որ փոքր, մեկուսացված ենթաբաղադրիչները քիչ են նպաստում թվաբանական և դինամիկ վերլուծությանը:

Սահմանում 1.1.11 (Գրաֆի տրամագիծ և շառավիղ). Գրաֆի տրամագիծը սահմանվում է որպես՝

$$\mathrm{diam}(G) = \max_{u,v \in V} d_G(u,v),$$

իսկ շառավիղը՝

$$\mathrm{rad}(G) = \min_{v \in V} \max_{u \in V} d_G(v,u).$$

Մեկնաբանություն 1.1.11. Տրամագիծը ցույց է տալիս սոցիալական ցանցի «լայնությունը»՝ առավելագույն հեռավորությունը երկու օգտատերերի միջև: Փոքր տրամագիծ ունեցող ցանցերը բնութագրվում են որպես «small-world» ցանցեր:

Սահմանում 1.1.12 (Երկկողմանի գրաֆ). Գրաֆը կոչվում է երկկողմանի, եթե $V = V_1 \cup V_2$, $V_1 \cap V_2 = \emptyset$և բոլոր կողերը միացնում են V_1-ի գագաթները V_2-ի գագաթներին (ոչ մի կող չի միացնում նույն ենթաբազմության երկու գագաթ):

Մեկնաբանություն 1.1.12. Թեև ընթացիկ մոդելը կենտրոնացած է օգտատեր–օգտատեր գրաֆի վրա, երկկողմանի ներկայացումը կարող է կիրառվել, եթե հետագայում ուսումնասիրվի օգտատեր–բովանդակություն կամ օգտատեր–խումբ տիպի կառուցվածք:

Սահմանում 1.1.13 (Լրիվ գրաֆ). Լրիվ գրաֆ K_nկոչվում է այն nգագաթ ունեցող գրաֆը, որի յուրաքանչյուր երկու տարբեր գագաթներ հարևան են:

Թեորեմ 1.1.14. Լրիվ գրաֆ K_n-ի կողերի քանակը հավասար է՝

$$|E(K_n)| = \binom{n}{2} = \frac{n(n-1)}{2}.$$

Ապացույց. Յուրաքանչյուր կող միացնում է երկու գագաթ, և կողերի քանակը հավասար է nգագաթներից 2-ական ընտրությունների թվին:

Մեկնաբանություն 1.1.14. Լրիվ գրաֆը նախագծում ծառայում է որպես տեսական «վերին սահման»՝ իրական սոցիալական ցանցի խտությունը գնահատելու համար: Իրական ցանցերը միշտ շատ ավելի նոսր են, քան K_n-ը, և հենց այդ տարբերությունն է բացահայտում դրանց կառուցվածքային յուրահատկությունները:

Սահմանում 1.1.15 (Ենթագրաֆ և ծնված ենթագրաֆ). Գրաֆ $H = (V_H, E_H)$-ը կոչվում է $G = (V, E)$գրաֆի ենթագրաֆ, եթե $V_H \subseteq V$և $E_H \subseteq E$: Եթե $S \subseteq V$, ապա $G[S]$գրաֆը, որի գագաթների բազմությունը S-ն է, իսկ կողերի բազմությունը՝ այն բոլոր կողերը, որոնց երկու վերջնակետերը S-ում են, կոչվում է S-ով ծնված ենթագրաֆ:

Մեկնաբանություն 1.1.15. Ծնված ենթագրաֆի գաղափարը կիրառվում է Louvain ալգորիթմով ստացված համայնքների վերլուծության ժամանակ: Յուրաքանչյուր համայնքը դիտարկվում է որպես S բազմություն, և $G[S]$-ի վրա իրականացվում են լրացուցիչ հաշվարկներ (կենտրոնականություն, link prediction և այլն):

Սահմանում 1.1.16 (Կողմնորոշված գրաֆ). Կողմնորոշված գրաֆը $\vec{G} = (V, A)$գրաֆ է, որտեղ $A \subseteq V \times V$բազմության տարրերը կարգավորված զույգեր են (u, v): Կողմնորոշված կողը (u, v)ներկայացնում է u-ից v ուղղությամբ կապ:

Սահմանում 1.1.17 (Մուտքային և ելքային աստիճան). Կողմնորոշված գրաֆում գագաթ v-ի մուտքային աստիճանը $d_G^-(v)$և ելքային աստիճանը $d_G^+(v)$սահմանվում են՝

$$d_G^-(v) = |\{u \in V : (u, v) \in A\}|, d_G^+(v) = |\{w \in V : (v, w) \in A\}|.$$

Մեկնաբանություն 1.1.17. Նախագծում կողմնորոշված գրաֆը կիրառվում է PageRank ալգորիթմի և տեղեկատվության հոսքերի վերլուծության համար, երբ կապերը ասիմետրիկ են (օրինակ՝ follow-տիպի հարաբերություններ): Մուտքային աստիճանը բնութագրում է օգտատիրոջ «հետևորդների» քանակը:

Սահմանում 1.1.18 (Կշռված գրաֆ). Կշռված գրաֆում յուրաքանչյուր կող $e \in E$-ի հետ կապված է $w(e) \geq 0$ քաշ, որը արտացոլում է կապի ուժը կամ ինտենսիվությունը:

Մեկնաբանություն 1.1.18. Սոցիալական ցանցի դեպքում w_{uv}-ը կարող է արտացոլել հաղորդագրությունների քանակը, ինտերակցիայի հաճախականությունը կամ այլ activity metric: Այս քաշերը անմիջապես կիրառվում են Linear Threshold մոդելում:

Սահմանում 1.1.19 (Հարևանության մատրից). Թող $V(G) = \{v_1, \dots, v_n\}$: Գրաֆի հարևանության մատրիցը $A(G) = (a_{ij})_{n \times n}$է, որտեղ

$$a_{ij} = \begin{cases} 1, & \text{եթե } v_i \text{ և } v_j \text{ հարևան են,} \\ 0, & \text{հակառակ դեպքում.} \end{cases}$$

Թեորեմ 1.1.20 (Հարևանության մատրիցի սիմետրիկություն). Եթե G գրաֆը պարզ և չուղղորդված, ապա նրա հարևանության մատրիցը սիմետրիկ է և գլխավոր անկյունագծում ունի զրոներ:

Ապացույց. Քանի որ գրաֆը չուղղորդված է, ապա v_iև v_jգագաթների հարևան լինելը համաչափ է՝ $a_{ij} = 1 \Leftrightarrow a_{ji} = 1$, ուստի A մատրիցը սիմետրիկ է: Պարզության պայմանը բացառում է ինքնակապերը, հետևաբար $a_{ii} = 0$ յուրաքանչյուր i-ի համար:

Մեկնաբանություն 1.1.20. Այս փաստը կարևոր է, քանի որ թույլ է տալիս կիրառել սպեկտրալ մեթոդներ այն դեպքերում, երբ սոցիալական կապերը փոխադարձ են (friendship), և գրաֆը դիտարկվում է որպես չուղղորդված :

Սահմանում 1.1.21 (Շրջակայք). Գրաֆում vգագաթի շրջակայքը (հարևանների բազմությունը) $\Gamma(v)$կամ $N_G(v)$է, որը սահմանվում է որպես բոլոր այն գագաթների բազմությունը, որոնք հարևան են v-ին՝

$$\Gamma(v) = \{u \in V : \{u, v\} \in E\}.$$

Լեմմա 1.1.22. Պարզ գրաֆում $d_G(v) = |\Gamma(v)|$:

Ապացույց. Յուրաքանչյուր հարևան $u \in \Gamma(v)$ համապատասխանում է մեկ կողի, և պարզ գրաֆում բազմակի կողեր չկան:

Մեկնաբանություն 1.1.22. Շրջակայքի հասկացությունը նախագծում կենտրոնական դեր ունի Adamic–Adar ցուցիչի և link prediction խնդիրների շարքում, քանի որ ապագա կապի հավանականությունը կապվում է ընդհանուր հարևանների կառուցվածքի հետ:

Սահմանում 1.1.23 (Գրաֆի խտություն). Պարզ, անկողմնորոշ գրաֆ $G = (V, E)$-ի խտությունը սահմանվում է որպես՝

$$\rho(G) = \frac{|E|}{\binom{|V|}{2}} = \frac{2|E|}{|V|(|V|-1)}$$

Մեկնաբանություն 1.1.23. Խտությունը չափում է, թե որքան «կապակցված» է սոցիալական ցանցը՝ $\rho(G) \in [0,1]$միջակայքում: $\rho(G) = 1$նշանակում է լրիվ գրաֆ, իսկ իրական սոցիալական ցանցերի համար սովորաբար $\rho(G) \leq 1$:

Սահմանում 1.1.24 (Կլաստերավորման գործակից). Գագաթ v-ի կլաստերավորման գործակիցը սահմանվում է որպես՝

$$C(v) = \frac{|\{(u,w) \in E : u, w \in \Gamma(v)\}|}{\binom{|\Gamma(v)|}{2}},$$

եթե $|\Gamma(v)| \geq 2$, հակառակ դեպքում $C(v) = 0$:

Մեկնաբանություն 1.1.24. Կլաստերավորման գործակիցը չափում է, թե որքան են հարևան գագաթները միմյանց հետ կապված: Բարձր կլաստերավորում ունեցող օգտատերերը կազմում են «սերտ շրջանակներ», ինչը ազդում է համայնքների հայտնաբերման և տեղեկատվության տարածման վրա:

1.2. Օգտագործվող ալգորիթմների սահմանումներ, բանաձևեր և բացատրություններ

Սահմանում 1.13 (Louvain ալգորիթմ և մոդուլայնություն). Louvain ալգորիթմը համայնքների հայտնաբերման հեուրիստիկ մեթոդ է, որի նպատակն է բարձրացնել գրաֆի մոդուլայնությունը Q՝ գտնելով գագաթների բաժանում համայնքների: Թող $m = |E|, A_{ij}$ լինեն հարևանության մատրիցի տարրերը, k_i՝ v_i գագաթի աստիճանը, իսկ c_i՝ այդ գագաթի համայնքի համարանիշը: Մոդուլայնությունը սահմանվում է.

$$Q = \left(\frac{1}{2m}\right) \cdot \sum_{\{i=1\}} \sum_{\{j=1\}} A_{ij} - \frac{(k_i\, k_j)}{2m} \cdot \delta(c_i c_j)$$

Բացատրություն Louvain ալգորիթմի փոփոխականների մասին.Այստեղ m-ը սոցիալական ցանցի կողերի ընդհանուր քանակն է (օգտատերերի միջև կապերի թիվը), A_{ij}-ը ցույց է տալիս, թե v_i և v_j օգտատերերը անմիջական կապ ունեն, թե ոչ, k_i-ը՝ v_i օգտատիրոջ աստիճանն է (կապերի քանակը), իսկ c_i-ը՝ այն համայնքի նշիչը, որտեղ գտնվում է տվյալ օգտատերը: $\delta(c_i, c_j)$ ֆունկցիան հավասար է 1, երբ երկու օգտատերերը նույն համայնքում են: Մեր նախագծում Louvain ալգորիթմը օգտագործվում է օգտատերերին ավտոմատ thematic/structure community-ների բաժանելու համար:

Սահմանում 1.14 (PageRank կենտրոնականության ցուցիչ). PageRank-ը կենտրոնականության ցուցիչ է կողմնորոշված գրաֆում, որը գնահատում է յուրաքանչյուր գագաթի «ազդեցիկության» մակարդակը: Թող N լինի գագաթների ընդհանուր թիվը, $In(v_i)$՝ այն գագաթների բազմությունը, որոնք ունեն կող դեպի v_i, իսկ $outdeg(v_j)$՝ v_j գագաթից ելնող կողերի քանակը: PageRank-ի բանաձևը.

$$PR(v_i) = \frac{1 - d}{N} + d \cdot \sum_{\{v_j \in In(v_i)\}} \frac{PR(v_j)}{outdeg(v_j)}$$

Բացատրություն PageRank ալգորիթմի փոփոխականների մասին. Այստեղ $PR(v_i)$-ն v_i օգտատիրոջ ազդեցիկության միավորն է, d-ն դամփինգ գործակիցն է (սովորաբար ≈0.85), N-ը՝ օգտատերերի ընդհանուր թիվը, $In(v_i)$-ն՝ բոլոր այն օգտատերերի բազմությունը, ովքեր «հղում» ունեն v_i-ի վրա (օրինակ՝ հետևում են նրան), իսկ $outdeg(v_j)$-ն՝ v_j օգտատիրոջ կողմից արված հղումների քանակը: Մեր սոցիալական ցանցի մոդելում

PageRank-ը թույլ է տալիս գտնել influencers կամ opinion leaders օգտատերերի մակարդակում:

Սահմանում 1.15 (Linear Threshold մոդել). Linear Threshold (LT) մոդելը նկարագրում է, թե ինչպես է տեղեկատվությունը կամ վարքագիծը տարածվում կողմնորոշված, կշռված գրաֆի միջոցով: Յուրաքանչյուր v գագաթի հետ կապված է $\theta_v \in [0,1]$ շեմ, իսկ $w_{\{uv\}} \geq 0$ քաշերը չափում են u-ի ազդեցությունը v-ի վրա և բավարարում են պայմանը $\sum_{\{u \in In(v)\}} w_{\{uv\}} \leq 1$: Թող A^0 լինի սկզբնական ակտիվ գագաթների բազմությունը: Յուրաքանչյուր քայլում t ≥ 1 գագաթ v-ն դառնում է ակտիվ, եթե.

$$\sum_{\{u \in In(v) \cap A^{t-1}\}} w_{\{uv\}} \geq \theta_v$$

Պրոցեսը կանգ է առնում, երբ այլևս նոր ակտիվացումներ չեն տեղի ունենում, և

$$cascade\ size = |A^{\infty}|$$

Բացատրություն Linear Threshold մոդելի փոփոխականների մասին. Մեր նախագծում θ_v շեմը ներկայացնում է, թե որքան «դիմադրող» կամ պահպանողական է v օգտատերը նոր տեղեկատվության կամ վարքագծի նկատմամբ: $w_{\{uv\}}$ քաշը գնահատում է, թե որքան ուժեղ է u-ի ազդեցությունը v-ի վրա (օրինակ՝ հաճախակի շփում, նույն համայնքի անդամություն և այլն): A^0-ն այն օգտատերերի բազմությունն է, որոնց սկզբում ենք «վարակում» տեղեկատվությամբ (seed set), A^t-ները՝ t-րդ քայլում արդեն ակտիվացած օգտատերերը, իսկ cascade size-ը ցույց է տալիս, թե ընդհանուր քանի օգտատեր է վերջում ընդունել տվյալ տեղեկատվությունը:

Սահմանում 1.16 (Adamic–Adar ցուցիչ). Adamic–Adar ցուցիչը կապերի կանխատեսման չափիչ է, որը գնահատում է երկու գագաթների նմանությունը նրանց ընդհանուր հարևանների միջոցով: Թող Γ(u) և Γ(v) համապատասխանաբար u և v գագաթների շրջակայքներն են: Այն դեպքում, երբ u և v կապ չունեն, Adamic–Adar-ի արժեքը.

$$AA(u,v) = \sum_{\{w \in \Gamma(u) \cap \Gamma(v)\}} \frac{1}{\log(|\Gamma(w)|)}$$

Բացատրություն Adamic–Adar ցուցիչի փոփոխականների մասին.Այստեղ Γ(u) և Γ(v) բազմությունները u և v օգտատերերի անմիջական ընկերների/կապերի ցանկերն են, Γ(w)-ը՝ w օգտատիրոջ հարևանների բազմությունն է: Եթե u և v ունեն քիչ, բայց «սերտ» (ցածր

աստիճան ունեցող) ընդհանուր հարևաններ, ապա AA(u, v)-ն մեծ է: Նախագծում այս ցուցիչը կիրառվում է գնահատելու, թե որ օգտատերերի զույգերի միջև է ամենայն հավանականությամբ առաջանալու նոր կապ (friend recommendation):